

线性探测实验分析报告

!? 线线?!

王露露

2026 年 10 月 2 日

前言

大二，没有学计算方法，没有学凸优化，甚至连概率论都没有学完，就要做机器学习实验，就要写机器学习作业，这合理吗？不!!!

线性模型已经是机器学习里面最简单的部分了但是同学们你们知道吗？还有一个名字里带线性的东西叫线性代数啊！到处都是线性代数啊！

Vibe Coding 自然而然会成为同学们的大救星：自然语言编程真的很爽啊！本报告和背后的代码也是完全 Vibe 而成。为了让没有梯子的同学能够感到一丝慰藉，本指南完全由国产大模型制作而成，花费 5-6 元。梁文峰在永久涨价后永久变为小难梁。

既然是由 AI 组成的报告，自然也不保证内容一定对或者一定能够复现。这里的“对”指的主要是第四节里面的推导和实验过程，对于一些结论性或启发性的内容，我还是很有把握的（大嘘）。如果想直接省流的话可以把第四节跳了。

1 数据

实验所给的数据来自 Qwen3-4B-Base 某层 decoder block 的输出（**final RMSNorm 之前**），每层 2560 维，数据格式为 float16；提供 layer 11 / 23 / 35 三层。

表 1: 两个任务的数据规模

任务	训练集	验证集	特征维度	取的 token	欠定?
world	500	130	2560	句末国家名	是 (500<2560)
truth	5088	300	2560	句末	否 (5088>2560)

- **world**: 标签是**具体地点**的经纬度（如”Lake Baikal, Russia?” $\rightarrow$ 53.5, 108.0），但特征只取**句末国家名的那个 token**。训练集 158 个国家、每国中位数 2 条、85 个国家内部有多个不同地点；验证集 78 个国家，与训练交集 59 个。经纬度范围约 $[-78.5, 64.1] \times [-159.8, 178.0]$ 。
- **truth**: 标签完全平衡（训练 2544/2544，验证 150/150）。

2 流程

1. **抽特征**: hook 指定层的输出，按选择取一个 token 的隐藏状态（world 取国家名 token、truth 取句末 token），存成 float16 的 .npy。

2. **读数据**: world 读 $(X, y) \in (\mathbb{R}^{N \times 2560}, \mathbb{R}^{N \times 2})$, truth 读 $y \in \{0, 1\}^N$ 。
3. **训模型**: world 对纬度、经度各训一个**独立**的线性回归; truth 训一个逻辑回归。
4. **选超参**: 标准化 (只用训练折统计量) 后, 做两轮 (λ_1, λ_2) 网格搜索 + 5 折交叉验证, 选出最优 λ 与层。
5. **提交**: 在完整训练集上重训, 输出权重; 若训练时做了预处理, 要把权重换算回原始尺度。

3 坑

3.1 学习率溢出

默认 $\text{lr} = 10^{-3}$ 在六种”数据 $\times$ 层”组合上全部越过临界学习率, 训练直接 **nan**。临界值 $\text{lr}_{\text{crit}} = 2/\lambda_{\max}(H) = N/\lambda_{\max}([X, 1]^\top [X, 1])$, 而且是一条悬崖: $0.99\text{lr}_{\text{crit}}$ 收敛、 $1.01\text{lr}_{\text{crit}}$ 发散。动手前先算 $\lambda_{\max}$, 或干脆标准化/调小学习率。

3.2 world 是欠定问题

$N = 500 < D = 2560$, 法方程 $X^\top X w = X^\top y$ 解不唯一; `np.linalg.inv/solve` 对数值奇异矩阵**不报错、只返回垃圾**。要唯一解得加 L2: $(X^\top X + N\lambda_2 I)$ 才正定。

3.3 特征尺度病态

各维尺度相差十几倍, 统一的 λ 会误伤小尺度特征, 先标准化。

3.4 岭参数量纲坑

题面损失 $L = \frac{1}{N} \|Xw - y\|^2 + \lambda_2 \|w\|^2$, 对应的岭参数是 $N\lambda_2$ (world 里就是 $500\lambda_2$), **不是** λ_2 本身; 用闭式解或 `sklearn` 时别直接拿 λ_2 当 λ_{ridge} 。

3.5 选型指标要对齐评分

分类若用 log-loss 选超参、最后按准确率评分, 二者秩相关是负的 ($\approx -0.59 \sim -0.89$), 会选错配置。评分看什么, CV 就用什么。

3.6 L1 次梯度振荡

把 $\text{sgn}(w_j)$ 当 L1 的”梯度”直接加, 会在 0 点来回跳、永远得不到零系数。应改用软阈值/近端算子 (`sklearn` 内部也是这么做的)。

3.7 L1 在本实验全程有害

这份表征是稠密/叠加的 ($\lambda_1 = 0.01$ 时最优解仍有 1860 个非零系数), 稀疏化只会丢信息; L2 (岭) 才有内点最优。

3.8 world 天花板很低

目标是地点坐标、特征却只有国家 token，坐标信息几乎读不出来——”同国家训练集平均坐标”(MSE 113.8) 都能赢过线性探针 (172.4)。别指望在 world 上刷出低 MSE。

3.9 层选择影响巨大

truth 上 L23 比 L11 高 14 个百分点，选对层比调 λ 更重要；三层都跑一遍。

4 探究流程

4.1 回归溢出：喜欢好不容易写完代码结果发现是 NAN 吗

4.1.1 现象

用固定学习率的梯度下降训练 world 任务（默认 $\text{lr} = 10^{-3}$ ），三层全部输出 Validation MSE: nan，并伴随大量 overflow encountered in matmul 警告。而 truth 任务（逻辑回归）用同样的学习率却没有报错，只是准确率平平。

4.1.2 根因：学习率阈值

线性回归的损失 $L(w) = \frac{1}{N} \|Xw + b - y\|^2$ 是二次型，其 Hessian 矩阵 $H = \frac{2}{N} [X, 1]^\top [X, 1]$ 与 w 无关。把 w 沿 H 的特征方向分解，则每次迭代后第 i 个分量乘以 $(1 - \text{lr} \cdot \lambda_i)$ 。如果固定学习率，那么只有当这个值的模长小于 1 的时候迭代才会收敛。于是收敛的充要条件是：

$$\text{lr} < \frac{2}{\lambda_{\max}(H)} = \frac{N}{\lambda_{\max}([X, 1]^\top [X, 1])} \equiv \text{lr}_{\text{crit}}. \quad (1)$$

关键在于这个阈值只要不严格遵守就会发散： $\text{lr} = 0.99\text{lr}_{\text{crit}}$ 收敛， $\text{lr} = 1.01\text{lr}_{\text{crit}}$ 以恒定倍率发散，中间没有过渡带。而且这个发散是指数速度的，多迭代几轮就爆炸了。

表 2: 六种数据 / 层组合的临界学习率。默认 $\text{lr} = 10^{-3}$ 全部越界。

	world L11	world L23	world L35	truth L11	truth L23	truth L35
$\lambda_{\max}([X, 1]^\top [X, 1])$	9.19e5	5.97e6	1.80e8	6.91e6	3.82e7	3.03e9
lr_{crit}	5.44e-4	8.37e-5	2.77e-6	7.37e-4	1.33e-4	1.68e-6
对应 $f = \text{lr}/\text{lr}_{\text{crit}}$	1.84	11.9	361	1.36	7.5	595

$\lambda_{\max}$ 跨了三个数量级，所以不存在能同时适配六种情况的单一学习率。

4.1.3 定量规律：溢出步数只取决于归一化学习率

记 $f = \text{lr}/\text{lr}_{\text{crit}}$ ，则主导方向每步放大 $\rho = |1 - 2f|$ ； $f > 1$ 时 $\rho = 2f - 1 > 1$ ， $|w|$ 按 ρ^k 增长，直到越过 $\log_{10}(\text{float64 上限}) = 308.25$ ：

$$k_{\text{ovf}} \approx \frac{308.25 - \log_{10} |c_0|}{\log_{10}(2f - 1)}. \quad (2)$$

实测预因子中位数 303.1，与 308.25 吻合；六组数据在同一 f 下的中位数离散度小于 0.6%—— k_{ovf} 只依赖 f ，与数据集、层数、学习率的绝对大小都无关。这正是图 1 左图里六条曲线完全重合的原因。




图 1: 左: 横轴换成归一化学习率 f 后, 六种数据 / 层塌缩到同一条曲线, 并与理论式 $k \approx 303/\log_{10}(2f-1)$ 重合; $f \leq 1$ 全部不溢出。右: 换成实际学习率后曲线分离——同一个 $lr = 10^{-3}$ 在 layer 11 对应 $f \approx 1.8$ (几千步溢出), 在 layer 35 对应 $f \approx 361$ (几乎立刻溢出)。

表 3: 实测溢出步数与理论式对照 (六组数据 / 层的中位数)。偏差稳定在 $-1.2\% \sim -2.2\%$, 负偏差来自主导模态的初始分量 $\log_{10}|c_0| \approx 4 \sim 7$ 。

f	1.02	1.05	1.10	1.20	1.50	2.00	3.00	5.00	10.0
实测	17691	7303	3820	2071	1007	636	435	319	238
理论	18097	7447	3893	2110	1024	646	441	323	241

4.1.4 为什么前几千步看不出来

$f > 1$ 时前几千步完全正常: 损失在下降, $\max_j |w_j|$ 稳定在 10^0 量级。原因是主导不稳定模态的初始分量极小 (10^{-5} 量级), 要经过数千步的指数放大才可见。图 2(a) 的放大插图直接显示了这一点。这意味着靠观察训练日志无法发现问题, 只能事先算 $\lambda_{\max}$ 。图 2(b) 给出了更严格的验证: 把横轴换成重整化轮次 $k \cdot \log_{10}(2f-1)$ 后, 五条曲线精确塌缩到 $y = x$ 上。




图 2: (a) $\log_{10} \max |w|$ 随轮次的变化: 先是长期平台, 随后突然竖直爆炸; 放大插图显示前 3000 步所有 f 都贴地。(b) 横轴乘上理论倍率后五条曲线塌缩成斜率 1 的直线。

4.1.5 逻辑回归不会溢出

交叉熵对 w 的梯度是 $\frac{1}{N}[X, 1]^\top(\sigma(z) - y)$ ，而 $|\sigma - y| \leq 1$ 恒成立： w 无法放大自身的梯度，不存在正反馈。实测把 lr 提到线性阈值的 **100 倍**，逻辑回归的 $\max |w|$ 仍只有 0.3，损失继续单调下降。它的失败模式是**慢或振荡，而不是报错**。

图 3 给出了损失与梯度范数的直接对照，图 4 则用一维剖面解释了机理：两者的损失在原点附近曲率相同，但二次损失在远处无上界，交叉熵则单侧饱和；对应的迭代映射斜率，线性恒为 $1 - 2f = -2$ （永久扩张），逻辑为 $1 - 12\sigma(1 - \sigma)$ ，在 $|t|$ 变大时回到中性 1。




图 3: (a) 线性回归损失: $f > 1$ 的曲线冲出画面并最终 **inf**; $f = 1.0$ 卡在 236 不降（临界：不发散也不收敛）。(b) 逻辑回归损失：五个 f 全部单调下降、全程有界。(c) 梯度范数：线性 $10^0 \rightarrow 10^{11}$ 指数上涨，逻辑稳定衰减。




图 4: (a) 损失函数沿主导特征方向的一维剖面（原点处曲率对齐）。(b) 梯度：线性 $\propto t$ 无界，逻辑 $\in (-8, 0)$ 有界。(c) 迭代映射的斜率——线性恒为 -2 （在稳定区之外，永久放大误差），逻辑在远处回到 $+1$ （中性）。这是两者行为差异的根本原因。

4.1.6 启示

注意如果要计算学习率阈值，必须用增广矩阵 $[X, 1]$ 。如果不考虑偏置项，只用 $X^\top X$ ，会低估 $\lambda_{\max}$ 约 0.05%，在步数较大的情况下可能会造成结果爆炸（指数级增长）。

如果使用 Adam 等优化器来实现梯度下降，本节的内容可以作为一个使用优化器的理由：合适的学习率自动调度策略可以保证迭代的收敛性。

从更高的层次来说，**数据分析**是所有机器学习任务中都非常重要的一环，可以说如果没有上面的数据分析，梯度爆炸了都不知道为啥。在数据预处理前，可以先用比较传统的方法对数据的特征

进行分析。有兴趣的同学可以在大二春季修读刘淇老师的数据分析及实践。

4.2 超参选型：网格搜索与 5 折交叉验证（学以致用这一块）

简要介绍一下网格搜索，这是一种联合调整多个超参数的办法，通过尝试在不同的超参数组合上评估模型效果来比较稳定地搜索表现较好的超参数组合。本质上就是个嵌套的 for 循环，把你选定的超参数排列组合试一遍。

4.2.1 两轮搜索怎么做

在标准化特征上（只用训练折统计量，无泄漏）对 (λ_1, λ_2) 做两轮搜索：

- **第一轮：** $\lambda_1, \lambda_2 \in \{0, 0.01, 0.1, 0.2, 0.5, 1\}$ ，共 36 组。其中 0 表示关闭该项，用于覆盖纯 L1 与纯 L2。
- **第二轮：** 以第一轮最优值为中心，向两侧各扩 0.75 个数量级（8 点 / 维），共 48 ~ 64 组。
- **5 折交叉验证：** truth 按标签分层（保证每折真假各半），world 用普通随机划分。

必须标准化的原因：正则化惩罚（ $\lambda_2 \|w\|^2$ 或 $\lambda_1 \|w\|_1$ ）只认权重 w 的大小，不认特征 x_j 本身的尺度。这批激活表征各维尺度相差十几倍，于是同样的信号强度，大尺度维度用一个很小的 w 就能表达，小尺度维度却得用一个很大的 w 才追得上；而惩罚是按 w 的大小收的，结果同一个 λ 会对小尺度维度产生很大惩罚、对大尺度维度几乎不惩罚。小尺度上的有用特征就这样被整片压掉，模型只敢用那些天生就很大的维度。

这个效应很大：world L11 在原始尺度上 CV MSE 最优只有 0.521，把每维都标准化成均值 0、方差 1 之后是 0.078——差 6.7 倍。标准化把各维拉到同一起跑线， λ 对每一维才意味着“同样强度的惩罚”，正则化强度才真正可调。

一个省时间的小技巧：网格搜索最慢的部分不是计算，而是反复读数据。把全部 K 组 (λ_1, λ_2) 的权重排成一个 (D, K) 的矩阵 W ，每轮迭代只做一次矩阵乘 XW （形状 $N \times K$ ），就把所有组合一起更新了。

为什么这样快？GPU 上的矩阵乘是“读内存受限”的：真正花时间的是把 X 从显存读进算核， X 一旦读进来，多算几列（ K 变大）几乎不增加额外时间。所以 K 从 1 涨到几十上百，单轮迭代的墙钟时间基本不变——这也是为什么没必要为了省时间而砍网格。

4.2.2 选择指标必须对齐评分指标

一个常见的直觉是：用 CV log-loss 选型，因为它比准确率平滑。但实测结果是，CV log-loss 与验证集准确率的 Spearman 秩相关是 $-0.59 \sim -0.89$ （负的）；换成 CV 准确率后是 $+0.88 \sim +0.99$ 。world 的 CV MSE 与验证 MSE 则是 $+0.985 \sim +0.992$ ，一直正常。

原因： $\lambda_2 = 0$ 的解被 sigmoid 饱和搞得极度过度自信——log-loss 很差，但排序并不差。所以“用更平滑的指标”是个陷阱：**评分看什么，就用什么选。**

4.2.3 CV 与验证集的一致性

把同一批 λ 组合在完整训练集上重训、在验证集上评估（图 5），可以看到：world 上 CV 选出的配置与验证集最优基本吻合（ $\lambda_1 = 0, \lambda_2 = 0.5$ ，CV 172.4 对验证最优 167.2）；truth 上 CV 与验证都选中了 L23 的相近 λ 。两个任务的最优层也完全一致。




图 5: 同一网格在验证集上的表现 (★ 为 CV 选出的配置)。world 的 CV → 验证迁移良好; truth 上分布差异更明显, 但层选择 (L23) 依然稳健。

4.2.4 启示

网格搜索之前先确认特征尺度: 各维相差十几倍时, 统一的 λ_1 会误伤小尺度特征, 标准化 (只用训练折统计量) 通常能把 CV 指标提升一个数量级。依然是数据预处理的力量。不过要注意: 按照只提交模型权重的要求来反推, 最终评分大概率会使用未经处理的原始输入。如果在正式训练的过程中使用了标准化, 那么提交的权重文件要重新处理, 从而恢复原有的数据尺度。

选型指标要和评分指标一致: 评分看准确率就用准确率选, 别为了“平滑”或其他原因改变指标。当然, 不同指标对任务的衡量可以作为实验报告中的一个展开点。

分类任务划分折时要按标签分层, 否则某些折里可能没有正样本, CV 结果会非常不稳。

4.3 两个正则化强度的探索与讨论: 我们都是有用的表征

4.3.1 最终配置

表 4: 两轮搜索得到的配置。两个任务都选了 $\lambda_1 = 0$, 即纯 L2 (岭回归)。

任务	层	λ_1	λ_2	CV 指标	验证集
world (经纬度)	11	0	0.5	CV MSE 0.0781	验证 MSE 172.4 (RMSE 13.1°)
truth (真假)	23	0	0.0562	CV 准确率 0.8734	验证准确率 0.8767

4.3.2 L1 完全无用——而且是有原因的

固定 λ_2 后 λ_1 的边际效应单调变差:

表 5: λ_1 的边际效应 (越右越差)。

λ_1	0	0.01	0.1	0.2	0.5	1
world L11 的 CV MSE ($\lambda_2 = 0.5$)	0.0781	0.0835	0.1286	0.1943	0.4428	0.9026
truth L23 的 CV 准确率 ($\lambda_2 = 0.1$)	0.8726	0.8599	0.7954	0.5000	0.5000	0.5000

truth 上 $\lambda_1 \geq 0.2$ 时模型直接塌成常数预测 (准确率 0.5)。

L1 的本职工作是特征选择, 为什么在 $D = 2560$ 维上反而有害? 答案是这份表征是稠密的——第 4.5 节会看到, $\lambda_1 = 0.05$ 时最优解仍有 982 个非零系数, $\lambda_1 = 0.01$ 时多达 1860 个。也就是说几乎每一维都带一点信息, 稀疏化只会丢信息。

这和大模型的认知是相通的: 不含 MoE 或稀疏激活的稠密模型, 信息并不集中在少数“关键神经元”里, 而是分布式地叠加在几乎所有维度上 (可解释性里叫 superposition)。因此对一份稠密表征做 L1 稀疏化, 本质是在强行拆散叠加在一起的信息, 反而有害。

4.3.3 L2 有明确的内点最优

与 L1 相反, λ_2 存在清晰的内部最优点。第二轮围绕 $\lambda_2 = 0.5$ 细化后的边缘曲线为:

表 6: world L11 在第二轮中的 λ_2 边缘曲线 (每点取该层最优 λ_1)。

λ_2	0	0.089	0.158	0.281	0.5	0.889	1.58	2.81
CV MSE	0.1001	0.0828	0.0809	0.0795	0.0781	0.0784	0.0803	0.0846

两侧都变差, 是标准的偏差—方差权衡形状 (图 6)。




图 6: 第一轮 6×6 网格热图 (★ 为该层最优, 颜色越深越好)。两个任务都呈现同一个模式: 沿 λ_1 方向变化剧烈, 沿 λ_2 方向几乎不变——这正是“ λ_1 有害、 λ_2 平缓”的直观体现。




图 7: 第二轮 λ_2 的边缘曲线（每点取该层最优 λ_1 ）。三条层曲线形状相似，都能看出 λ_2 的 U 形最优，但整体高度由层决定。

4.3.4 层的作用大于正则化

表 7: 层对指标的影响远大于 λ 。

	L11	L23	L35
world 验证 MSE	172.4	235.2	205.3
truth 验证准确率	0.7333	0.8767	0.8000

truth 上 L23 比 L11 高 14 个百分点；两个任务的最优层还不同——这提示中间层与后层编码的信息类型不一样。

4.3.5 启示

L1 不是“默认更好”的正则化：只有当特征真的稀疏时它才做得到特征选择。这份预训练表征是稠密的（ $\lambda_1 = 0.01$ 时最优解仍有上千个非零系数），强行稀疏只会丢信息；L2（岭）在稠密表征上总能找到内点最优，是更稳妥的默认。

对于每个隐藏层的特征而言，最优/较优的正则化系数并不完全相同。可以对不同的层使用不同的最优正则化系数，再最终比较结果。

4.4 解析解：能不能直接求出最优权重矩阵

上课的时候我们讲过（肯定讲过）线性回归在不含有 L1 正则项时有解析解。与其费劲巴拉优化梯度，何不直接把解析解弄出来？但是实际上这个方法的可行性是比较低的。

4.4.1 结构性结论：不唯一

world 是 $N = 500, D = 2560$ 的欠定问题：中心化后 $\text{rank}(X) = 499, \text{rank}(X^T X) = 499 < 2560$ ，条件数约 10^{15} （图 8）。法方程 $X^T X w = X^T y$ 的解是一个 2061 维的仿射子空间——有无穷多个 w 都能让训练损失精确为 0，它们彼此无法区分。因此“求出最优权重矩阵”严格来说无解；能求的是“某个”最优解。




图 8: 中心化训练矩阵的奇异值谱：第 499 个之后直接掉到机器精度。这解释了为什么 $X^T X$ 数值奇异、法方程无唯一解。

4.4.2 六种解析途径的实测对比

表 8: 各种解析途径在 world L11 上的表现 (验证集 130 条)。

办法	训练 MSE	验证 MSE	$\ W\ $	说明
<code>np.linalg.inv</code>	2.47×10^8	2.31×10^{10}	1.0×10^6	不报错，但是纯垃圾
<code>np.linalg.solve</code>	0.0000	9.50×10^5	9523	不报错；完美插值但泛化极差
伪逆 <code>pinv</code>	≈ 0 (10^{-26})	395.0	88.0	最小范数解
SVD 截断	≈ 0	395.0	88.0	保留 499/500 个奇异值
<code>lstsq</code>	≈ 0	395.0	88.0	最小范数解
岭回归闭式解	59.6	172.4	44.1	唯一最优解

三个要点：

1. `inv` 与 `solve` 都不抛异常。`numpy` 只对严格奇异的矩阵报错；数值奇异时它会静默地返回垃圾。`inv` 的结果之所以连训练集都拟合不了，是因为它在 10^{-15} 量级的主元上做了除法，误差被放大 10^6 倍。
2. 伪逆 / SVD / `lstsq` 给出同一个**最小范数解**，训练 MSE 精确到 1.0×10^{-26} （即完美插值），但验证 MSE 高达 395。
3. **只有加上 L2 正则化**， $(X^T X + N\lambda_2 I)$ 才严格正定、最优解才唯一。这从另一个角度解释了为什么网格搜索一路指向“必须有正则化”。

图 9 给出了完整的岭路径：训练 MSE 单调下降，验证 MSE 先降后升的 U 形。




图 9: 岭路径 (横轴 $\|W\|$ 随 λ 增大而减小)。训练集 MSE 单调下降，验证集 MSE 先降后升——过拟合与欠拟合的直接可视化。由于纵轴是对数尺度，这个先降后升不太明显，但确实存在。

4.4.3 训练集最优解在验证集上的表现

把最小范数解 (训练 $\text{MSE} = 0$) 放到验证集上: $\text{MSE} = 395.0$ 。作为参照:

表 9: world 验证集上的横向对比 (全部 130 条)。

预测方式	验证 MSE
全局均值	3311
训练集最优解 (最小范数)	395.0
岭回归 (CV 选的 $\lambda_2 = 0.5$)	172.4
同国家训练集平均坐标	113.8

训练集上的最优解比正则化解差 2.3 倍，比“同国家均值”基线差 3.5 倍。它比瞎猜好 8 倍，但基本就是在记忆训练样本——500 个样本配 2560 个自由参数，自由度是样本数的 5 倍，插值毫无难度。

4.4.4 一个容易踩的坑

实验文档的损失是 $L = \frac{1}{N} \|Xw - y\|^2 + \lambda_2 \|w\|^2$ ，令梯度为零得 $(X^\top X + N\lambda_2 I)w = X^\top y$ 。也就是说岭参数 $\lambda_{\text{ridge}} = N\lambda_2 = 500\lambda_2$ ，不是 λ_2 本身。如果直接拿 λ_2 当 λ_{ridge} 塞进闭式解或 `sklearn`，网格会整体停在欠正则区域 (最优值顶在网格边界)，看起来“越大越好”，其实是量纲搞错了。

4.4.5 启示

欠定问题 ($N \ll D$) 的解析解不唯一, 而 `np.linalg.inv/solve` 对数值奇异矩阵不会报错, 但返回的矩阵无用。所以解线性方程组请用 `lstsq` 或显式加正则化, 别把”没报错”当成”算对了”。

”训练 $MSE = 0$ ”表明模型已经在插值——500 个样本配 2560 个自由参数, 训练损失为 0 毫无难度, 但验证损失可能直接拉完。

解析闭式解和迭代法 (近端梯度) 在相同 λ 下给出验证 MSE 172.3770 与 172.3772——吻合到 5 位有效数字, 两种思路互相印证, 调试实现时是很有用的一招。

4.5 三种求解器实现的差别: 梯度下降 / 坐标下降 / sklearn

4.5.1 次梯度在零点振荡

如果把 L1 的次梯度 $\lambda_1 \text{sgn}(w_j)$ 直接加进梯度 (最自然的写法), 配合固定步长, 会在 0 附近振荡——这正是实验文档提示过的现象。量化结果: $\lambda_1 = 5$ 时目标值比最优高 58; 更严重的是 **它永远得不到精确的零系数** (2560 维全部非零), L1 的稀疏化能力完全没发挥。问题出在 $|w_j|$ 在 0 点不可导、次梯度不唯一: 拿 $\text{sgn}(w_j)$ 当梯度, 权重会在零点两侧来回跳, 永远落不到精确的 0 上。

4.5.2 改进: 把 L1 换成软阈值近端算子

$$S(z, t) = \text{sign}(z) \cdot \max(|z| - t, 0). \quad (3)$$

L1 从”梯度里的一项”变成”梯度步之后的精确投影”, 这个算子能把权重精确地压到 0。两种经典实现:

- **单变量坐标下降**: 每轮只优化一个 w_j 。该一维子问题对弹性网有闭式解, 正是软阈值 $w_j \leftarrow S(\rho_j/n, \lambda_1/2) / (G_{jj}/n + \lambda_2)$; 逻辑回归的一维子问题无闭式解, 用 2 步近端牛顿再套软阈值 (glmnet 的做法)。
- **近端梯度 (ISTA/FISTA)**: 对整个权重向量同步施加软阈值的版本。

4.5.3 逻辑回归: 三方完全一致

表 10: truth 上四种实现的目标值 / 非零系数个数。ISTA、坐标下降、sklearn 吻合到 10^{-16} , 非零系数逐个对上。

(λ_1, λ_2)	原次梯度	近端梯度 ISTA	坐标下降	sklearn (saga)
(0.01, 0.05)	0.411105 / 2560	0.409398 / 417	0.409398 / 417	0.409398 / 417
(0.05, 0.05)	0.635658 / 2560	0.580495 / 78	0.580495 / 78	0.580495 / 78
(0.10, 0.00)	0.889410 / 2560	0.655853 / 20	0.655853 / 20	0.655853 / 20

原次梯度版目标值分别差 1.7×10^{-3} 、 5.5×10^{-2} 、 2.3×10^{-1} , 且**非零系数始终为 2560 个**。

4.5.4 线性回归: ISTA 追平 sklearn, 坐标下降被拖垮

表 11: 线性回归上与 sklearn 最优目标值的差距 (差值越小越好)。


模型	(λ_1, λ_2)	原次梯度	近端梯度 ISTA	坐标下降
纬度	(0.01, 0.05)	$+1.6 \times 10^{-4}$	-8.7×10^{-10}	+2.25
纬度	(0.10, 0.00)	$+1.6 \times 10^{-1}$	$+1.4 \times 10^{-7}$	+0.62
经度	(0.01, 0.05)	$+3.2 \times 10^{-4}$	-8.2×10^{-7}	+16.9
经度	(0.10, 0.00)	+4.5	$+7.6 \times 10^{-6}$	+8.4

ISTA 与 sklearn 的非零个数**全部完全一致**。坐标下降的公式本身没错 (在合成良态数据上与 sklearn 差 1.8×10^{-11} 、非零个数一致), 但在 world 上收敛极慢:

表 12: 收敛速度对比 (world · 纬度, $\lambda_1 = 0.01$, $\lambda_2 = 0.05$; sklearn 最优 8.348562)。

求解器	累计耗时	与最优的差距
坐标下降 200 遍	18.4 s	+3.00
坐标下降 800 遍	69.0 s	+0.99
坐标下降 1600 遍	134.6 s	+0.48
ISTA 200 步	0.1 s	+0.123
ISTA 1000 步	0.7 s	$+2.0 \times 10^{-4}$
ISTA 20000 步	14.1 s	-8.7×10^{-10}

ISTA 跑 0.1 秒就超过了坐标下降跑 135 秒的结果。原因是 world 是 $N \ll D$ 的欠定问题, Gram 矩阵秩只有 500、特征极度共线; 坐标下降的收敛率由受限条件数决定, 在这种退化结构下极差, 而近端梯度的步长直接锚在 $\lambda_{\max}$ 上, 对共线性不敏感。坐标下降并非不能用——它在良态问题上精确、在逻辑回归上与 sklearn 一致——只是被 $D \gg N$ 这个特定结构拖垮了。

图 10: 三个模型 $\times$ 三组 λ 下, 四种实现与 sklearn 最优值的差距 (对数轴)。




图 11: 同预算下两种求解器的收敛速度: ISTA 用不到 14 秒到达 10^{-9} , 坐标下降跑 135 秒仍差 0.48。

4.5.5 一个反直觉的现象

λ_1 较大时, 原次梯度版的验证集指标反而更好: world 经度 561.8 对 ISTA 的 909.0; truth 准确率 0.8100 对 0.7867。原因是它根本没收敛——权重停留在离原点更近的位置, 等效于更强的隐式正则化。”没解对”在验证集上偶然占了便宜, 但这不是可以依赖的性质, 而且它永远拿不到真正的稀疏解。

4.5.6 启示

把 $\text{sgn}(w)$ 当成 L1 的”梯度”直接加进梯度下降会导致得不到精确的零系数, 使用软阈值/近端算子才能得到稀疏解, sklearn 的 `saga/liblinear` 内部也是这么实现的。

求解器的选择取决于问题结构: 良态问题上坐标下降又快又准, 退化 ($N \ll D$ 、高度共线) 问题上近端梯度更稳。

最后, 用 sklearn 当”标准答案”来对照自己实现的求解器, 是排查 bug 的好办法——目标值和稀疏结构都对上, 才算真的对。

5 创新点

下面的内容可以作为附加实验为你的报告增光添彩:

1. 线性回归收敛所要求的学习率上限分析及实验
2. 学习率的动态调度策略探究以及优劣分析 (可了解并分析常见的优化器)

3. 不同数据预处理方法（中心化、标准化、特征工程等）下线性模型的表现优劣分析
4. 网格搜索与 k-fold 交叉验证选择最优超参数
5. L1 正则化的精细调参和大模型隐藏层表征稠密的分析
6. 线性回归解析解的存在性和最优性探究（引入 L2 正则化构造唯一最优解）
7. 梯度下降不同实现方法的下降流程/结果差异（重点分析 L1 正则化能否出稀疏解）
8. sklearn 中涉及到的具体优化细节研究

做人留一线，日后好相见。请看到这里的同学不要把八个实验全都做一遍并写进自己的报告。原因有以下两点：一、可能不止你一个人看了这个指南；二、助教可能会被你的实验报告累死。

在这里我要做一个免责声明：本人不对读者使用以上创新点可能造成的大量报告雷同和助教精神问题负责。

6 注意事项

- 标准化统计量**只能来自训练折**，提前用验证集就是数据泄漏。
- truth 划分折时要**按标签分层**，否则某折可能没有正样本。
- world 的最终评分是**原始尺度** MSE（不是标准化后的），别被标准化后的小 MSE 骗了。
- 用 `sklearn` 当“标准答案”对照自己实现的求解器：目标值和稀疏结构都对上才算对。
- 学习率、正则化的默认值都不靠谱，所有超参数都需要调参，以及相应的消融实验和可视化。
- truth 样本充足（5088），world 样本稀缺（500），两者的调参策略和期望指标要分开看待。**如果想要你的 world 任务性能更出色，那就去部署 Qwen4B 采集更多数据吧**
- 人工特征构造（PCA、去顶主成分、随机投影、随机傅里叶特征、平方拼接、行归一化、幂变换）共 9 类、数十种强度，**没有任何一种可靠胜过基线**：world 上配对 bootstrap 的 95% 置信区间全部跨 0，truth 上 McNemar 检验 $p \in [0.23, 1.00]$ 。特征工程宜作为附加实验探究，不要在提交的权重上做特征工程（提交规范本身也不允许）