

线性探测实验数据扩增报告

王露露

2026 年 10 月 4 日

前言

相信你已经看过报告 1 了，如果没有也不要紧，反正是 AI 生成的。我猜这个实验会让同学们难忘的，至于怎么个难忘法就取决于同学们的表现和助教的批改严格度了。这篇报告主要有以下三个部分：

- world 一共 500 条训练数据，解析解都不固定，要不自己造点数据吧
- 既然是经纬度，可视化之后长啥样？
- 把所有隐藏层的数据都拼起来训练一个线性模型，看我力大砖飞！

由于 boss 已经进入二阶段，我选择 GPT6.1 Sol 作为我的 Viber。本阶段的所有工作和报告均由我指导 GPT6.1 Sol 完成。别问为什么不用 Astra，问就是没充 Pro。

本文中加粗的内容是人工写的。

[illegible]

1 地理数据重采样的构造流程

1.1 为什么重新构造数据

原 world 训练集只有 500 条，每个单层却有 2560 个输入维度。少量地点难以覆盖全球位置变化，提示我们进一步考察训练数据规模的影响。这里的“重采样”是从独立地名库中选择新的地点实体，构造问题并重新采集隐藏层表征。

我们将标签构造与模型特征采集分开：GeoNames 提供地点及坐标，Qwen 提供问题的隐藏层特征。这样不需要依赖小模型正确回答经纬度，避免将模型生成错误直接写入监督标签。

1.2 地点选择与标签

地点来自 GeoNames 的 cities15000 快照，以城市、居民点和各级行政中心为主。只接受 PPL、PPLA、PPLA2、PPLA3、PPLA4 和 PPLC 类型，排除历史、废弃居民点及城市内部子区等其它类型。该来源也包含部分人口较少的首都，不意味着所有地点人口都超过 15000。

采样按国家/地区代码轮流选取，每个代码最多 600 条；国家内部兼顾 10° 地理网格和三个档位的人口规模：小于 10 万、10 万至 100 万、至少 100 万。桶内优先选择人口较大的地点，以兼顾空间覆盖和模型较可能识别的名称。这不是按地表面积均匀采样，也不是各大洲等量采样。

经纬度标签原样取自 GeoNames 的 WGS84 坐标，单位为十进制度，北纬和东经为正。CSV 及回归目标的列顺序固定为“纬度、经度”。每条记录还保留实体 ID、来源链接、行政区、人口、地物类型和来源修改日期，便于追溯。

城市标签是地名库代表点，不是城市所有位置的精确坐标；GeoNames 支持社区编辑，也可能存在误差。

1.3 原始标签来源的推测

原课程没有公开 world 数据集的构造方式，因此无法直接确认坐标标签来自哪个地理资源。为检验其是否与常见城市数据库一致，我们对原标签与 GeoNames、Simplemaps 免费城市库的公开镜像以及 Wikidata 坐标进行了对照。先按名称和国家匹配城市，Wikidata 则通过 GeoNames 实体 ID 关联；存在歧义时不按坐标距离挑选候选，以避免人为提高相似度。最终在三种资源共同匹配的 247 个城市上进行比较。

资源	距离中位数 (km)	平均距离 (km)	完全一致条数
GeoNames	1.160	2.102	0
Simplemaps 公开镜像	1.127	2.467	13
Wikidata	1.221	2.146	7

表 1: 原始标签与三个地理资源的坐标相似性；仅比较共同匹配的城市。

Simplemaps 镜像的距离中位数略小，且有更多坐标与原标签完全重合；GeoNames 的平均距离则更小。中位数差异的配对 bootstrap 区间均跨越零，因此没有稳定证据认定某一资源总体更接近。当前结果不支持原标签统一原样复制自任一被测快照，但不能排除使用历史版本、不同城市代表点，或综合多个地理资料整理标签。

一种可能的解释是，原标签采用了公开网页或地理数据库中常见的城市坐标，而不是统一读取我们使用的 GeoNames 快照。不过，这只是与结果相容的猜测：资源之间可能共享数据，人工摘录或模型生成也可能产生相同坐标。坐标接近不能证明来源相同，也不能据此判断标签是否来自 Qwen。比较以城市为主，尚不覆盖原数据中的全部湖泊、山峰和建筑；Simplemaps 使用注明来源和许可的第三方镜像，未验证其等于官方最新版本。新增数据的来源则是明确的：直接采用 GeoNames 坐标作为监督标签，Qwen 仅负责提供隐藏层表征。

此外，我们不排除使用模型回答构造原标签的可能。坐标的小数位数受来源、提示词和输出格式影响，不能单独作为区分数据库标签与模型回答的依据。**我个人更倾向于数据集是以某些公开地理数据为基础构造的。**这一倾向仅是来源猜测，尚无构造代码或来源记录支持。

1.4 问题构造与表征采集

英文提示词采用以下格式：

What's the longitude and latitude of {place}, {admin1}, {country}?

行政区用于消歧；缺失或与地点、国家同名时省略。国家保留在问号之前，便于与原课程的 country token 提取规则保持一致。坐标标签不出现在问题中。

使用非量化 Qwen/Qwen3-4B-Base，固定 revision 为 906bfd4b4dc7f14ee4320094d8b41684abff8539。模型仅做前向传播，不使用聊天模板，也不生成答案。对每个问题提取国家名最后一个重叠 token 在 0-based block 11、23、35 中的输出，包括第 35 层也在最终 RMSNorm 之前取值。

云端 RTX5090 完成采集，权重及计算使用 BF16，特征保存为 float16。每层数组形状为“样本数 $\times$ 2560”，与 CSV 逐行对齐。采集后检查了数据、权重和特征文件的完整性；相关配置及 SHA256 保存在采集记录中。

1.5 数据集规模与划分

新增数据共 12000 个独立地点实体，覆盖 235 个 GeoNames 国家/地区代码，随机种子为 20261004。

划分	地点数	国家/地区代码数	用途
train	8382	211	训练与拟合预处理参数
valid	1050	163	新数据分布下的超参数选择
test	1050	163	训练见过国家内的新地点测试
test_unseen	1518	24	留出国家/地区的外推测试

先按大洲分层留出约 10% 的国家/地区代码作为 test_unseen，再将其余地点按约 80/10/10 划分；样本不足 3 条的国家全部进入 train。同一实体不跨新增划分，重复或含糊的提示词被剔除。原课程地点按名称和别名作保守排除，但不能保证识别所有拼写变体。

test_unseen 的国家不出现在新增 train 中，其用途是区分“熟悉国家内的新地点定位”和“对新国家的外推”。未见仅指线性探测头训练未见，不代表 Qwen 预训练未见。上述代码数量按 GeoNames 字段统计，不作政治实体数量认定。

新数据以城市为主，原数据还包含山峰、湖泊和建筑，存在对象类型及提示词分布差异。增加城市数据不能被等同于对原任务各类地物的全面补充。

1.6 新验证集选型与原数据合并评估

为考察仅依赖新增数据选型时的跨域表现，本轮仍只使用新 train 的 8382 条训练，并使用新 valid 的 1050 条选择隐藏层、L2 强度和最佳迭代。原 train 的 500 条与原 valid 的 130 条合并为 630 条跨域评估集，均不参与本轮训练或选型；新 test 及 test_unseen 也不参与选型。原数据此前已被多轮查看，因此这是一轮选型时留出的跨域评估，而非全新的盲测。

模型采用单隐藏层全批量动量梯度下降，从零权重初始化，不使用解析解或 L1。先比较 L11、L23、L35 及七档 L2，再依据新 valid 细调 L11。最终选择 L11、L2=0.002、学习率约 0.00138619、动量 0.9，在 40000 步达到本轮迭代上限；相对梯度约为 3.22×10^{-6} ，不宣称完全收敛。标准化参数和标签均值只从新 train 计算。

数据集	条数	MSE	距离中位数 (km)
新 train	8382	9.43	272.6
新 valid (选型)	1050	18.25	347.5
新 test	1050	18.65	334.0
test_unseen	1518	538.53	2539.8
原 train	500	273.60	987.6
原 valid	130	219.81	894.8
原数据合并	630	262.50	967.7

表 3: 仅按新 valid 选型的单层梯度模型；原数据两部分均在选型完成后评估。

合并 MSE 按全部 630 条的两个坐标维度计算，等于原 train 与原 valid 的 MSE 按 500 与 130 加权平均。原 train 对本轮模型是未参与拟合的评估数据，其 273.60 不能解释为本轮训练损失。

本轮模型的新 test MSE 为 18.65，但原 valid MSE 为 219.81，高于旧训练集 L11 模型的 172.38，未见国家 MSE 也达到 538.53。这表明新城市分布上的低误差不能保证原地物分布或未见国家上的改

善。此前按原 valid 选型的扩增模型得到 153.68，而本轮为 219.81，体现了选型目标对结果的影响，不能把前者视为独立测试获胜。旧模型使用过原 train，因此其原数据合并分数也不能与本轮 262.50 作公平的测试对照。

1.7 数据扩增效果的适用范围与限制

本阶段采用新增 train 的 8382 条数据单独训练，未将原 500 条训练数据合并进去。因此，实验同时改变了样本数量、地点类型和提示词分布，不能把新旧模型的全部差异归因于数据量增加。扩增主要覆盖城市，且地域分布仍不均衡；其收益首先适用于训练已见国家内的新城市定位，尚不能推广到山峰、湖泊、建筑等全部地物。

此前按原 valid 选型的 L11 梯度下降模型，在新城市 test 上的 MSE 为 25.93，低于原 500 条训练的 L11 模型的 169.15；原验证集 MSE 则由 172.38 降至 153.68。不过，该扩增模型的层、正则强度和迭代步数均按原验证集选择，而旧模型采用训练集交叉验证选型，两者训练方法也不同。因此，原验证集上的约 10.8% 下降只是不同选型协议下的观察结果，不能作为独立测试证明，也不足以单独证明数据扩增的因果收益。下文另报告仅按新 valid 选型的实验，以区分两种评估用途。

未见国家上的表现也不支持全面改善：上述单层模型的 test_unseen MSE 由 311.25 降至 267.49，但定位距离中位数由约 1255 公里升至 1829 公里。MSE 下降与典型样本的距离误差改善并不等价，国家外推仍是明显短板。另一个固定三层组合的样本量对照中，新增 500 条与 8382 条训练的城市 test MSE 分别为 81.18 和 15.11，而 test_unseen MSE 反而由 185.19 升至 358.06；该对照仅使用一次随机抽样，尚需多种子学习曲线验证其稳定性。

特别提醒：该数据集的构造方法以及分布和原有数据集不一定（甚至可以说几乎不可能）完全一致，只是在验证集上获得了一定范围的效果验证。使用该数据集进行训练不保证能够获得比使用原训练集训练更好的测试误差。

2 世界地图上的数据分布

2.1 原始训练集与验证集




图 1: 原训练集 500 条数据的地理分布




图 2: 原验证集 130 条数据的地理分布

在全球尺度的地图上，原训练集和验证集都呈现明显的稀疏点状分布。它们虽然涉及多个大洲，但国家和地区内部往往只有少数观测点，许多位置区间缺乏连续覆盖。验证集仅 130 条，地图上的稀疏性更加明显。

这里的“稀疏”指地理观测点数量少、位置覆盖有限，并不是隐藏层特征或权重的稀疏性。从图上只能观察覆盖特征，不能单凭视觉证明小样本导致了全部预测误差。

2.2 新增地点与叠加对照




图 3: 原训练、原验证、新增全部地点及叠加对照

新增 12000 个地点让地图上的观测点明显变密。欧洲、东亚、南亚以及部分美洲和非洲区域出现更连续的城市覆盖，补充了原数据中只有零星地点的区域。叠加图也显示，覆盖增加不是在原点上反复复制，而是加入了大量新位置。

不过，点位分布仍不均匀：城市集中区较密，沙漠、高纬地区及人口稀少区域较稀。新增地点中北半球 9954 条、南半球 2046 条，北半球占 82.95%；原 train 和 valid 的北半球比例分别为 73.4% 和 70.0%。更多点不意味着更均衡的全球样本。

地图展示的是新增的全部采样。test_unseen 中的地点也在绿色点中，因此不能把整张新增图当作线性模型训练时实际见过的覆盖范围。

如果你想试试的话，可以把全部的新增数据都用来训练并在原来的验证集上做测试。

事实上，从上面的图可以看出来，GPT 构造的数据集采样地区大量集中在欧洲、南美、东南亚等地区，还是有很大偏向的。大家如果要手动构造数据采样，记得让 Coding Agent 按照某些规则（比如所属大洲、地区人口密度等）做一下采样地区的分布查验，避免出现过大的分布偏差。

值得注意的是，新增采样中朝鲜半岛的数据点密度似乎异常高，这可能是由于 GPT 按照软件的地理分区轮流采样而非地理面积密度均匀。如果仔细看上面的地图，还能发现很多面积较小的地区采样点非常密集。

数据集附在评课社区。

2.3 可视化如何帮助解释实验

地图直观支持了扩大地点覆盖的动机，但实验表现还需要结合标签类型与划分方式理解。新增城市分布更密，与同类城市测试改善相一致；原数据包含的自然地标、建筑和极地站点仍未被城市采样同等覆盖。因此，训练数据增加与跨数据域泛化改善是两个不同的问题。

在固定三层组合的单次抽样对照中，新 500 条训练的城市 test MSE 为 81.18，新 8382 条为 15.11，支持增加同域地点有帮助。这只是一个随机种子的对照，不是完整学习曲线；原课程验证集和未见国家的结果并未获得同样稳定的改善。

底图仅使用 Natural Earth 陆地轮廓，不含国界线。所有地图范围一致，坐标直接来自 CSV，原数据已知标签偏差未作修正。等距圆柱展示会放大高纬区域面积，点位重叠及标记大小也影响观感，因此这些图不能直接作为单位地表面积的密度估计。

3 拼接隐藏层是否优于单层

3.1 对照设计

Qwen3-4B-Base 每个隐藏层的特征为 2560 维。单层模型仅使用 L11、L23 或 L35；拼接模型将同一问题的多个层输出横向连接，两层为 5120 维，三层为 7680 维。拼接只是增加线性模型的输入维度，不改变任务标签。

为了使不同层处于可比较的尺度，每维先按训练数据的均值和标准差进行标准化，再拼接。world 使用 L2 岭回归，truth 使用带 L2 的逻辑回归；偏置不参与正则化。每个组合分别选择正则强度，避免将单层最优参数直接套到拼接模型上。

本节原数据拼接实验通过训练集 5 折交叉验证选型，再在完整训练集上拟合并评估验证集；新增数据拼接对照使用新增 valid 选型。单层梯度实验则分别按原 valid 与新 valid 选型，见第 1 节。不同协议的结果分别报告，不将验证损失混为同一套选型证据。

3.2 原数据上的效果

任务与配置	输入维度	正则强度 L2	验证结果
world, L11 单层	2560	0.5	MSE 172.38
world, L11+L35	5120	1.0	MSE 153.63
world, L11+L23+L35	7680	1.0	MSE 153.51
truth, L23 单层	2560	0.1	准确率 0.8700
truth, L11+L23+L35	7680	0.3	准确率 0.8733




图 4: 原数据中单层与不同拼接组合的效果比较

world 三层拼接相较最佳单层的验证 MSE 降低约 10.9%，训练集交叉验证也支持拼接。不过，L11+L35 与三层结果几乎相同，说明 L23 在另外两层之上的增量有限。原验证集只有 130 条，三层与 L11 的配对 bootstrap 差值区间跨越零，因此只能说点估计有改善，不能宣称统计显著。

truth 的三层拼接只比 L23 多正确预测 1 条验证样本，交叉验证反而更偏好单层，McNemar 检验也不支持显著改善。由此可见，增加特征维度并不自动带来更好的预测。

3.3 为什么两个任务表现不同




图 5: 不同层的预测相关性与残差相关性

world 各层的预测相关性约为 0.97，但残差相关性仅为 0.53—0.68：它们对大致位置的判断相近，却并不总在相同样本上犯同样的错误。拼接可能利用这些互补信号。残差相关性较低不等于误差统计独立，但为融合改善提供了机制解释。

truth 则主要依赖 L23，L35 与它存在较强冗余，L11 单层也较弱，额外输入未必能提供有价值的信息。融合是否有效，取决于新增层是否带来互补信息，而不是层数本身。

3.4 新增城市数据上的对照

以下模型均在新增 train 的 8382 条数据上训练，层与 L2 只按新增 valid 选择。数值来自同一轮搜索，不混入之后按原 valid 选型的单层模型。

配置	L2	新 valid MSE	新 test MSE	test_unseen MSE
L11	0.003	18.32	18.72	488.38
L23	0.003	42.24	39.34	903.39
L35	0.01	36.80	35.43	427.82
L11+L23+L35	0.01	14.17	15.11	358.06




图 6: 新增数据各层与三层拼接的正则化路径

在同类城市测试集上，三层拼接比 L11 单层的 MSE 降低约 19.3%，支持多层信息具有一定互补性。但未见国家误差仍然很大，拼接没有解决国家外推问题。本组实验采用岭回归谱分解求解，主要比较输入表征；后续最终单层模型另使用动量梯度下降训练。

注意实验最终提交要求只使用一个隐藏层，因此拼接特征只能作为附加探究，不能替代提交模型。此前作为提交候选、按原 valid 选型的梯度模型使用 L11、L2=0.03，原 valid MSE 为 153.68；新增的按新 valid 选型模型使用 L11、L2=0.002，原 valid MSE 为 219.81。前者的原 valid 参与了层、正则强度和迭代选择，后者本轮仅用其作跨域评估。两者均不能与本表不同搜索及求解协议的结果直接比较融合收益。

4 讨论与结论

表征拼接和数据扩增分别考察输入信息与样本覆盖对模型的影响。world 实验中，多层拼接表现出一定的互补价值，而 truth 没有可靠收益；自主城市采样增加了地点数量和局部覆盖，但保留了明显的地域分布偏差，并引入与原地物任务不同的数据域。

本次结果支持：在所报告的选型协议下，拼接降低了部分 world 评估集的误差，单次样本量对照支持增加城市样本有助于同域定位。不过，仅按新 valid 选型的单层模型在原 630 条数据上的 MSE 为

262.50，原 valid MSE 为 219.81，未优于旧训练集模型的 172.38。扩增尚未证明对原任务具有稳定收益，也未解决未见国家外推问题。提交模型仍须使用单隐藏层，拼接作为探究结果保留。

5 创新点

这篇报告引出了以下可能作为附加实验或探究的内容：

1. 更多数据的构造方式探索和所训练模型的效果比较：尝试使用更多的地点、更权威的地理数据进行数据构造，并探究其训练模型的表现。**这里要注意到底选取哪些数据作为验证集和测试集：是你生成数据的一部分，还是原有的数据？注意验证集的信息可能会通过调超参、早停等流程向你的模型泄露**
2. 数据本身的地理分布特征：利用可视化来研究数据本身的特征，对数据集本身的质量做出评估。
3. 线性模型在未见地区的泛化性研究：如果你的线性模型只见过亚欧大陆的数据，但验证集全都是美洲的地点会如何？模型是否还能正确输出相应的经纬度？为什么？**本思路同样适用于对自然/人文等按其他方法分类的探索**
4. 拼接隐藏层信息：隐藏层拼接本质上是一种特征工程，可以探究从多个隐藏层中提取的特征是否对实验效果有显著提升，并总结原因。
5. 隐藏层层数对线性模型效果的影响：实验要求提交你的模型权重和你选择的隐藏层层数，但并没有限制层数只能从提供的三个当中选。可以探究究竟哪一层的特征提取出来效果最好。当然这需要大量的数据采样，且极有可能只能当作探究内容。**如果你真的准备使用原来没有提供数据的隐藏层（11，23，35 以外的层），请先向助教询问是否允许这么做!!!**
6. 模型表征和 prompt/token 的相关性分析：如果改变问模型的问题，结果会怎么样？当前的问题格式为 “What’s the longitude and latitude of 地名，国家”，如果删去国家，对模型的效果会不会有影响？如果只输一个地名给模型而不提示 ta 输出经纬度，还能提取出经纬度吗？
7. 预测准确率的地理分布探究：哪些地点在你的模型下预测最准确？哪些最不准确？这会不会在地理上呈现一些规律？

与此同时，推荐大家有空读一下实验中提到的有关研究的论文原文，链接在实验要求有。

6 数据与图像来源

- GeoNames 数据下载及字段说明 (<https://download.geonames.org/export/dump/>)，数据许可为 CC BY 4.0。
- Qwen 模型固定版本(<https://huggingface.co/Qwen/Qwen3-4B-Base/tree/906bfd4b4dc7f14ee4320094d8b41684abff8>)
- Natural Earth 陆地轮廓(<https://www.naturalearthdata.com/downloads/110m-physical-vectors/110m-land/>)。