

线性探测的非线性与生成式基准对照

王露露

2026 年 10 月 5 日

前言

这篇报告应该是这次实验的**最后一舞**。燃烧吧，小宇宙！

我们之前执着于分析数据，研究线性模型的方方面面。到这里，一个很自然的问题就冒出来了——我们辛辛苦苦搞出来的线性模型，到底有没有触及这份表征能给出的效果上限？换言之，我们怎么知道指标到底掉到多少才算优秀？ $MSE < 1000$ 吗？100 呢？如果有一个模型在验证集上拿到了几乎为 0 的 MSE，我们真的能信任 ta 吗？还是说 ta 在测试集上可能存在不稳定的表现？

本报告主要从模型效果入手，主要完成了以下几个工作：

- 使用自己训练的全连接**神经网络**来拟合 world 的经纬度，看看到底怎么个事。我都这么大力了怎么还没砖飞
- sklearn 全家桶直接启动启动启动，把所有的办法全都试一遍，看看这个任务的上限到底在哪
- 在地图上，经度 +179 和 -179 好像只差 2 度，但是 MSE 损失差几万，用球面距离当损失会不会更合理
- 数据是用 Qwen4B 生成的，那我们直接问问 Qwen4B 不就好了?!
- 线性模型到底好在哪？为什么？对这个任务来说为什么适配？

本报告由 GPT6.1、Deepseek V4.1-flash 辅助完成
省流部分直接看每章的结尾，以及文末创新点。

1 自行训练的全连接神经网络

1.1 数据来源与划分用途

先给一张”谁用哪份数据”的总表，后面所有实验都按这张表对号入座。

实验组	训练集	验证与调参集	选型后评估集
原数据网络	课程 train, 500 条	课程 valid, 130 条	新 test, 1050 条; 新 test_unseen, 1518 条
新数据网络	GeoNames 新 train, 8382 条	新 valid, 1050 条	新 test、新 test_unseen; 课程 valid, 130 条; 另汇报原 train 及合并 630 条

原数据网络没有独立的课程测试集，原 valid 结果属于选型结果。对新数据网络，课程 valid 不参与该组层、超参数或停止轮次选择，属于跨数据域评估；但它此前已被本项目多次查看，不能称为全新盲测。原 train 与 valid 合并后的 630 条，只能用于没有在原 train 拟合的新增数据模型作跨域评估，不能作为原数据网络的独立测试集。

1.2 结构、优化与选型过程

比较三种结构：2560→2 的线性头、2560→64→2 的单隐藏层网络，以及 2560→128→64→2 的双隐藏层网络；隐藏层使用 ReLU。这里需要特别区分：网络的隐藏层数与输入取自 Qwen 的第几层是两个完全不同的概念，三个结构均只输入一个 Qwen 层。

首先只用各组训练集计算逐维特征均值和标准差。目标坐标按训练均值中心化，并用两维共同的 RMS 尺度缩放，保留纬度和经度之间的 MSE 权重；评估时恢复为十进制度。采用 float32 全批量 AdamW，学习率搜索 0.001、0.003，权重衰减搜索 0、0.01，偏置不衰减，梯度范数裁剪为 10，不使用 L1 正则化。

每组先搜索 3 个 Qwen 层 × 3 种结构 × 2 档学习率 × 2 档权重衰减，共 36 个配置；最多 400 轮，验证损失连续 50 轮未改善则停止，保存最低验证 MSE 检查点。随后对每种结构的验证最优配置延长至最多 1200 轮，耐心值 100，并以 20261005、20261006、20261007 三个随机种子重复训练。每次检查点仍只按该组验证集选择，测试集不用于早停，也不挑选表现最好的种子。延长阶段只复训初搜短名单，因此不保证 1200 轮预算下的全局最优；部分训练达到上限，仍可能未充分收敛。

最终双隐藏层配置：原数据选择 L35，新数据选择 L11，两者学习率均为 0.001、权重衰减均为 0.01。首种子原模型最佳轮次 49、停止 149；新模型最佳 836、停止 936。原数据较早过拟合，新增数据可以支持更长训练，这本身就暗示了限制在原数据一侧。

1.3 结果与线性参照

下表为三个种子的 MSE 均值 ± 样本标准差，表示重复训练的波动，既不是置信区间，也不是三个网络集成后的分数。

训练来源	结构	原 valid	新 valid	新 test	test_unseen
原 train	线性头	342.01±17.57	630.64±13.30	592.81±26.71	707.33±190.74
原 train	MLP-64	204.48±8.31	198.90±23.65	189.32±22.78	291.15±41.44
原 train	MLP-128-64	152.70±9.17	119.69±8.77	118.80±7.38	183.26±34.14
新 train	线性头	209.32±20.42	19.79±0.15	19.61±0.10	465.24±64.31
新 train	MLP-64	155.06±14.50	7.42±0.24	7.71±0.27	277.56±31.56
新 train	MLP-128-64	142.81±9.50	5.43±0.15	6.02±0.36	170.09±16.16




图 1: 两种训练来源下网络结构的效果比较




图 2: 各组网络的训练与验证损失曲线

新增数据双隐藏层网络在新 test 上显著降低了点估计误差；其原 valid 均值也较低，但原模型在原 valid 上调参，新模型在新 valid 上调参，不能将二者差异全部归因于数据量。首种子两模型原 valid MSE 分别为 160.64、139.51，配对 bootstrap 差值区间跨越零；未见国家差值区间也跨越零，跨域改善尚不能视为可靠的普遍结论。

这里必须泼一盆冷水：本组原数据 AdamW 线性头的 342.01 并不是线性方法的最佳水平。下一节直接按原 valid 选型的岭回归达到 167.17，而 KNN 达到 125.27。故网络优于本组线性头，不足以证明所有非线性模型都优于充分调参的线性模型。网络结构、优化器与正则化配置共同影响结果，不能拿一个没调好的线性头去给”非线性”背书。

1.4 小结

神经网络在量很少的数据集上很容易过拟合，这点请务必注意：world 任务的原始训练集仅有 500 条。与此同时，不应把优化神经网络损失当作本实验的最终目标，但仍需结合训练和验证损失检查过拟合及优化是否充分：**这个实验是线性模型实验，神经网络再强大也只能给出一个参考。**

当然，神经网络过拟合也是有很多判据的，如果做神经网络相关的额外实验，可以试着判断模型有无过拟合。

2 sklearn 回归方法

2.1 两组实验的数据协议

实验组	训练来源	验证与选型来源	测试或评估来源
原数据回归	课程 train, 500 条	课程 valid, 130 条	本组主要汇报原 valid, 无独立原测试集
新数据回归	新 train, 8382 条	新 valid, 1050 条	新 test、新 test_unseen; 原 train+valid 合并 630 条, 并分别报告两部分

原数据组每种方法的层和超参数均按原 valid 最低 MSE 选择，不能与报告 1 按训练集交叉验证选型的数值混作相同协议。新增数据组先完成新 valid 选型，再读取原数据评估标签；原 630 条不参与这一轮选型。所有标准化和 Nyström 映射仅在相应训练集拟合，不使用验证或测试数据统计量。

2.2 方法与调参过程

原数据组实际拟合 204 个候选配置，新增数据组拟合 159 个配置，均搜索 L11、L23、L35。普通最小二乘和岭回归同时预测两维；SVR 及梯度提升为纬度、经度分别训练回归器。KNN 搜索邻居数 1、2、3、5、10、20 及 uniform/distance 权重。随机森林和 ExtraTrees 采用 150 棵树，搜索深度 10 或不限、叶节点最少样本 1 或 5，特征子采样为 sqrt。梯度提升采用 100 棵树，深度 2 或 3、学习率 0.05 或 0.1，同样使用 sqrt 特征子采样。

原数据岭回归 alpha 搜索 0.01 至 5000 的十档；新增数据搜索 1、3、10、30、100、300、1000。sklearn 岭回归使用平方误差总和加 alpha 乘权重平方和；若与此前“平均平方误差加 lambda 正则项”的目标比较，须按 $\alpha = n \times \lambda$ 换算，不能直接比较参数数值——这一点和报告 1 的岭参数量纲坑是同源的。

RBF-SVR 搜索 $C=10、100、1000$ ， $\gamma=0.0001、0.0004、0.001$ ， $\epsilon=0.1$ 。新增数据采用预计算的精确 RBF 核矩阵减少重复计算，并非核近似。原数据核岭回归使用精确 RBF 核， $\alpha=0.01、0.1、1、10$ 及相同 gamma 网格；新增数据为控制计算量改用 512 分量 Nyström 映射加岭回归，因此单独命名，不能作为精确核岭的纯样本量对照。

原数据还实际训练 sklearn MLPRegressor：结构 64 或 128-64，ReLU 与 Adam， $\alpha=0.0001$ 或 0.01，学习率 0.0003、0.001、0.003；目标采用共同尺度还原，全批量逐轮 partial_fit，最多 400 轮、原 valid 耐心值 60，保存最佳检查点。新增数据组没有另行重训 sklearn MLP，神经网络对照引用上一节 PyTorch 三种子结果，不能误写为本组新增训练的 MLPRegressor。

2.3 原数据选型结果

方法	Qwen 层	原 valid MSE	距离中位数/km
KNN	L35	125.27	584.49
RBF-SVR	L11	147.01	729.70
岭回归	L11	167.17	923.12
精确 RBF 核岭	L11	177.69	877.09
普通最小二乘	L23	304.68	1535.81
梯度提升	L11	371.82	1720.36
ExtraTrees	L11	414.54	1822.07
随机森林	L11	491.00	2128.19
sklearn MLP	L11	723.93	2398.21




图 3: 原数据验证集上的回归方法比较

最佳 KNN 为 3 邻居、距离加权；SVR 为 $C=1000$ 、 $\gamma=0.0001$ ；岭回归 $\alpha=500$ 。KNN 与岭回归的原 valid 配对 MSE 差为 -41.90 ，但 bootstrap 区间跨越零，且存在验证集选型偏差。KNN 训练误差近零来自训练样本包含自身邻居，不能作为泛化能力证据。OLS 与 ExtraTrees 也可几乎完全拟合 500 条训练数据，但验证误差很大，再次强调了高维小样本中的正则化需求——这与报告 1 里”训练 MSE=0 毫无难度、验证才见真章”是同一个道理。

sklearn MLP 的 723.93 与 PyTorch MLP 的 152.70 来自不同优化、初始化、搜索预算和重复次数，不能据此否定神经网络模型族，也不能把实现名称当成效果保证。

2.4 新数据训练后的同域与跨域表现

各方法仍按新 valid 独立选择配置。下表传统模型为单次拟合，PyTorch MLP 为三种子均值，重复预算不同。

方法	新 valid	新 test	test_unseen	原 valid	原合并 630 条
RBF-SVR	7.90	7.23	469.71	273.58	319.53
KNN	13.08	12.42	683.74	221.36	277.87
岭回归	18.44	18.82	466.53	194.38	247.88
普通最小二乘	20.96	21.17	876.83	335.81	347.94
ExtraTrees	34.97	28.61	831.24	483.17	609.38
随机森林	48.71	44.96	658.14	558.89	693.16
Nyström-RBF 岭	56.12	53.97	229.91	230.23	271.18
梯度提升	91.36	87.03	393.06	565.31	681.27
PyTorch MLP-128-64	5.43	6.02	170.09	142.81	176.15




图 4: 新数据训练后同域及跨域误差比较

新增传统方法中，按新 valid 应选择 L11 的 SVR， $C=1000$ 、 $\gamma=0.0004$ ；不能看到原测试分数后改选岭回归，再宣称自己遵循了同一协议。SVR 新 test 优于岭回归，但原 630 条误差反而更大，说明同域最优不保证跨域最优。其新 test 样本与训练特征的最大 RBF 相似度中位数约 0.972，原 valid 约 0.795，未见国家约 0.370，支持”分布变化”是值得进一步探究的因素，但相关性不构成因果证明。

对于线性优化，岭回归是重要的稳定参照：原 valid 调参可到 167.17，新 valid 调参后新 test 为 18.82。小网络和 SVR 的同域优势提示非线性结构可能有价值，但新增城市覆盖不能替代原任务的地物覆盖。原数据已经反复参与历史分析，跨域测试结论仍需要新的保留样本验证。

2.5 小结

机器学习有大量的方法来解决回归任务，线性回归是最基础的一种，也常常被作为更高级学习方法的 baseline。如果某个模型在某个任务上的效果明显优于线性模型，那么一般认为线性模型在任务中的复杂度过低，存在通过特征构造等方法优化模型效果的可能。那么反过来，**利用比较高级的模型来拟合我们的表征探索任务，可以作为更优解是否存在的探索。**

从经验主义和实用主义的视角来说，如果其他更复杂的回归模型在可比较的选型协议和合理调参预算下仍然无法获得比线性模型更好的学习效果，那么可以将线性模型视为当前条件下的良好基准，但不能证明它已达到最优。本次部分非线性方法在原 valid 或新 test 上取得了更低 MSE，其收益仍取决于数据分布和评分指标。

3 truth 任务的 sklearn 分类基准

3.1 数据集来源与文本构造探究

为判断课程 truth 句子是否具有公开数据集来源，我们将本地 train 与 valid 逐句对照 CREAK 作者公开仓库中的 train、dev、test_without_labels 及 contrast_set。匹配不使用真假标签作为检索条件；对空白字符归一化后统计匹配句子，并检查公开标签与课程标签是否一致。结果如下：

课程划分	总数	直接匹配句数	匹配比例	标签冲突数
train	5088	4380	86.08%	0
valid	300	190	63.33%	0

表 6: 课程 truth 与 CREAK 公开句子的对应关系，按本地句子计数，不重复计算跨公开划分出现的句子。

训练集直接匹配句子全部来自 CREAK 的 train；验证集 190 条匹配句中，166 条仅匹配 dev，21 条仅匹配 contrast_set，2 条同时匹配这两个划分，另 1 条同时匹配 contrast_set 与公开无标签 test。可检查的公开标签均与课程标签一致。本地 5388 条句子无完全重复。该证据明确支持 CREAK 为课程数据的主要来源，但课程 valid 混合了不同公开划分，并非官方 dev 的原样副本。

未直接匹配的 708 条训练句和 110 条验证句尚未全部逐条溯源。代表性近似匹配显示，部分课程句子对应 CREAK 原句，但包含拼写或语法改动，例如 makes 被改为 mkaes、danced 被改为 dnaced，以及 are the only ones 被改为 is the only ones。抽查支持文本扰动的解释，但不能据此断言所有未匹配句都来自同一种修改流程，也不能确认修改发生于课程制作阶段还是中间版本。

CREAK 由 Onoe 等人在 2021 年提出，原始训练集含 10176 条陈述、dev 含 1371 条，作者仓库的更新版 contrast_set 含 500 条。其构造以 Wikipedia 实体为种子，让 Amazon Mechanical Turk 众包人员独立编写真、假陈述并提供理由；评估数据经过作者人工筛选，对比集则通过小幅修改句子改变真假。这里的 Wikipedia 主要提供实体背景，并不意味着句子直接复制自百科或标签由知识库自动赋值。标签来源是人工编写与标注体系，匹配证据不支持将课程标签解释为 Qwen 自己的判断。来源见<https://github.com/yasumasaonoe/creak>及论文<https://arxiv.org/abs/2109.01653>。

这一区分影响实验解释：truth 同时涉及实体知识和常识判断，文本扰动还可能改变表征；课程验证分布不能直接等同官方 CREAK 评估分布，也不能将当前准确率与官方排行榜直接比较。公开数据可能出现在语言模型预训练语料中，但仅凭公开来源不能确认 Qwen 是否训练过这些句子。后续可通过匹配实体、原始解释和扰动类型分组分析错误；本次只完成来源调查，不新增模型测试。

3.2 数据来源与评估协议

本组读取课程 LAB1/datasets/truth 的 train.csv 及 valid.csv，以及逐行对应的 L11、L23、L35 隐藏层数组。train 有 5088 条，真假各 2544 条；valid 有 300 条，真假各 150 条。label=1 表示句子为真，label=0 表示句子为假，沿用课程标签；本实验没有独立核验所有句子的事实。新增 GeoNames 城市数据只有坐标标签，不含真假标签，因而不能用于 truth 训练或验证。这里的”两个数据集”明确指课程 train 和 valid 两个划分。

所有候选模型只在 train 拟合，逐维 StandardScaler 也只使用 train 统计量。valid 用于选择每种方法的 Qwen 层与超参数：准确率越高越好，同分保留搜索顺序中最先出现的配置。随后报告各方法选定模型的 train 和 valid 指标，没有合并两组重新拟合。valid 同时参与选择与效果汇报，因此这些结果属于验证分数，不是独立测试准确率；训练分数也不能作为泛化证据。

3.3 分类器、搜索与复核过程

搜索三个单 Qwen 层，不拼接。逻辑回归使用 L2 正则化， $C=0.01, 0.1, 1, 10$ ，最多 2000 次迭代；线性 SVM 使用相同 C 网格、对偶求解，最多 500 次迭代、容差 0.01，这是为控制高维求解开销设定的预算。RBF-SVC 搜索 $C=0.1, 1, 10$ ， $\gamma=0.0001, 0.0004$ 。KNN 搜索 3、5、15 个邻居及 uniform/distance 权重。随机森林和 ExtraTrees 各使用 150 棵树， $\max_features=\sqrt{\cdot}$ ，叶节点最少样本为 1 或 5。直方图梯度提升使用 100 轮、学习率 0.1，叶节点数 7 或 15。共计每层 26 个配置，三层 78 个候选；随机种子 20261005，不选择最佳随机种子。完整搜索表记录收敛警告，达到迭代上限的配置不能视为充分收敛的模型族上限。

主要指标是准确率，补充正类 F1、平衡准确率和混淆矩阵。两组均类别均衡，平衡准确率等于普通准确率；恒定预测任一类别的基准准确率为 50%。本轮没有采用概率校准，不报告不具备统一概率含义的模型之间的交叉熵。保存完整搜索记录、选定模型和两组逐条预测，并重新加载全部七个模型核验预测一致性。

3.4 两个划分上的效果

方法	Qwen 层	train 准确率	valid 准确率	valid 正类 F1
RBF_SVC	L23	96.13%	87.00%	0.8746
LogisticRegression	L23	96.23%	86.67%	0.8710
LinearSVC	L23	99.88%	85.00%	0.8515
HistGradientBoosting	L23	98.90%	84.67%	0.8535
ExtraTrees	L23	100.00%	84.67%	0.8487
RandomForest	L23	99.67%	83.00%	0.8381
KNN	L23	82.31%	79.67%	0.8076




图 5: truth 分类器在 train 与 valid 上的准确率

方法	选定超参数	选定模型收敛记录
RBF_SVC	{"C": 1, "gamma": 0.0004}	无警告
LogisticRegression	{"C": 0.01}	无警告
LinearSVC	{"C": 0.01, "dual": true, "max_iter": 500, "tol": 0.01}	无警告
HistGradientBoosting	{"max_leaf_nodes": 15, "max_iter": 100, "learning_rate": 0.1}	无警告
ExtraTrees	{"n_estimators": 150, "min_samples_leaf": 1, "max_features": "sqrt"}	无警告
RandomForest	{"n_estimators": 150, "min_samples_leaf": 5, "max_features": "sqrt"}	无警告
KNN	{"n_neighbors": 15, "weights": "uniform"}	无警告

本轮按 valid 准确率选出的最佳方法为 RBF_SVC，输入 L23，验证准确率为 87.00%，参数为 {"C": 1, "gamma": 0.0004}。上述排序来自同一个 300 条验证集上的多配置选择，存在选型偏差；一次拟合和有限搜索也不足以证明某类分类器普遍最佳。高训练准确率与验证准确率的差距应结合各方法的容量理解：本轮 ExtraTrees 训练准确率为 100%，验证仅 84.67%，说明完全拟合训练标签并不保证泛化。KNN 训练预测包含自身邻居，也应谨慎解读。RBF-SVM 比逻辑回归仅多判对 1 条验证样本，不支持明显的非线性优势。

对线性优化而言，逻辑回归与线性 SVM 提供了直接的单层线性分类参照，非线性 SVC 与树模型用于判断增加表达能力是否具有额外收益。分类准确率与 world 的坐标 MSE 单位和含义不同，不放入同一个数值排行榜。进一步优化应冻结层和超参数，并在新增、未参与选型的 truth 样本上评价，同时考虑句子来源、模板及事实类别的分布变化。

3.5 各分类模型的表现与解释

逐条把七个模型的结果读一遍，比只看排行榜更有信息量——准确率相同不代表预测行为相同。

逻辑回归：L23、C=0.01，训练 96.23%、验证 86.67%，即 260/300 条正确，正类 F1 为 0.8710。验证集中 25 条假句被判真、15 条真句被判假。它直接使用仿射打分和 sigmoid，是本轮最贴近课程提交

模型的参照；较强正则化的配置被选中，说明训练拟合程度不是唯一目标。

线性 SVM: L23、C=0.01，训练 99.88%、验证 85.00%，即 255/300 条正确，F1 为 0.8515。验证误报 24 条、漏报 21 条。它与逻辑回归具有相同的线性判别边界形式，但采用间隔损失；训练几乎满分而验证稍低，说明改变损失不能自动改善泛化。选定模型没有收敛警告，不过整个搜索采用有限迭代预算，不能据此认定充分优化后的 SVM 必然较差。

RBF-SVM: L23、C=1、gamma=0.0004，训练 96.13%、验证 87.00%，即 261/300 条正确，F1 为 0.8746。其误报 25 条、漏报 14 条，与逻辑回归相比总计只多正确 1 条。它借助核函数形成非线性边界，是本轮最高验证点估计，但优势很小；依赖支持向量的预测无法压缩成课程要求的一组原始 2560 维线性权重。

KNN: L23、15 邻居、均匀投票，训练 82.31%、验证 79.67%，即 239/300 条正确，F1 为 0.8076；误报 39 条、漏报 22 条。训练和验证差距较小，但两者均低于线性基准，提示当前标准化特征下的局部距离投票不足以充分读出真假信号。此结论仅针对当前距离和邻居网格，不能推广到所有度量学习方法。

随机森林: L23、150 棵树、叶节点最少 5 条，训练 99.67%、验证 83.00%，即 249/300 条正确，F1 为 0.8381；误报 33 条、漏报 18 条。训练拟合很强而验证较弱，表明当前树容量和特征子采样组合存在较大的泛化差距，增加非线性容量没有带来优势。

ExtraTrees: L23、150 棵树、叶节点最少 1 条，训练 100%、验证 84.67%，即 254/300 条正确，F1 为 0.8487；误报 25 条、漏报 21 条。更随机的分裂取得了略高于随机森林的验证点估计，但完全拟合训练标签仍不足以超过逻辑回归。

直方图梯度提升: L23、100 轮、学习率 0.1、最多 15 个叶节点，训练 98.90%、验证 84.67%，同样 254/300 条正确，F1 为 0.8535；误报 30 条、漏报 16 条。它与 ExtraTrees 准确率相同但误报、漏报分布不同，说明准确率相同不代表预测行为相同。两者都没有显示相对线性基准的明显收益。

所有选定模型均使用 L23，支持”层选择比本轮分类器替换更加稳定”这一判断。上述差距是有限网格、单随机种子和同一验证集上的描述性比较，不构成各模型族能力的排序证明。

3.6 符合提交格式的线性模型可达到水平估计

按课程实现，truth 预测形式为 $\text{sigmoid}(x \cdot w + b)$ ，使用一个 Qwen 层的原始 2560 维特征，提交 weights 形状为 (2560,)、bias 为标量；默认以概率 0.5 区分真假，即按仿射分数是否大于零判别。这里不拼接层，不引入平方项、交叉项、核映射、额外文本规则或非线性网络。目标是估计此模型族在当前数据上的可达到水平，而不是为它给出未经证明的数学上界。

逐维标准化不会扩大这一模型族：若标准化模型为 w_z, b_z ，则原始尺度的第 j 维权重为 $w_j = w_{z,j}/s_j$ ，偏置为 $b = b_z - \sum_j w_j _j$ 。这些变换可以完全吸收到提交权重中，预测阶段无需人工特征工程。本轮逻辑回归已按此公式导出到 `evidence/truth_linear_baseline.npz`，并在全部 300 条 valid 上核验与 sklearn 预测完全一致；它是 86.67% 的可提交形式基准，不是新的最优模型。线性 SVM 的硬分类边界也可以写成同样的仿射形式，但其 sigmoid 数值不具有逻辑回归概率校准意义，若课程还评分交叉熵则不能只凭准确率替代逻辑回归。

线性证据	输入与配置	选型依据	原 valid 准确率
本轮逻辑回归	单层 L23, C=0.01	原 valid 搜索	86.67%, 260/300
本轮线性 SVM	单层 L23, C=0.01	原 valid 搜索	85.00%, 255/300
报告 1 既有逻辑回归	单层 L23, L1=0, L2=0.0562	训练集分层交叉验证	87.67%, 263/300

报告 1 还汇报了上述纯 L2 配置的交叉验证准确率约 87.34%。结合本轮与历史证据，较合理的工作估计是：在已有特征、当前数据分布和现有训练规模下，充分调参的单层仿射分类器验证准确率约为

87%—88%；目前已达到的最好报告点估计是 87.67%。它不是“最高只能到 88%”的结论，也不是隐藏测试集的保证。不同正则化定义、优化预算和选型协议应分别对待，不能直接比较 C 与历史 L2 的数值。

300 条验证样本中 1 条对应 0.33 个百分点，87.67% 与本轮 RBF-SVM 的 87.00% 仅相差 2 条。因此，目前证据不支持非线性分类器显著突破线性方法。若仅作为样本量不确定性的示意，263/300 的 95% Wilson 区间约为 83.46%—90.92%；该区间未修正模型选择和反复查看验证集的偏差，不能用 90.92% 作为线性模型上限。

有限配置搜索只证明某个分数能够达到，不能证明更高分数不可能。要进一步估计经验性能平台，应仅在训练集做分层交叉验证、细化 L2 与优化收敛设置，冻结层和配置后在新的独立 truth 测试集评价；可补充多种子、训练样本量曲线。当前没有独立测试集，故本报告只给出可达到水平及其不确定性，不宣称求得线性模型理论上限。

3.7 小结

对 truth 数据集本身的分析已经指向了公开数据集，并发现部分文本改动（如改变部分单词的拼写等），但不能确认这些改动是否出于数据增强目的及其实际收益。有兴趣的同学可以研究数据增强并讨论这样做的意义。

分类任务在 sklearn 中也有大量的方法可以使用，后面的课程应该也会讲到，所以暂时不知道分类器内部的细节不用太担心。如果你在报告中涉及了其他的分类器，请务必保证至少要弄懂效果最好的几个。

与此同时，分类任务的指标意义一定要搞明白。你至少要知道以下几个名词的意义和来源：accuracy, precision, recall, F1, ROC, AUC

4 Qwen4B 直接输出坐标

本节我们会把 world 数据集中的地点输入已部署的 Qwen4B 模型并令其输出对应的经纬度。这应该是我目前能想到最极端的提升 world 任务指标上限的办法。

4.1 数据来源与推理协议

本组使用固定版本的非量化 Qwen/Qwen3-4B-Base。模型没有在任何本项目 train 或 valid 上进行任何监督微调，也没有训练回归头，因此本组不存在“训练集”或“用于优化模型权重的验证集”。原 train 和原 valid 只是沿用课程文件名，均作为生成评估输入：分别 500 条、130 条，合并 630 条。原标签仍采用课程坐标，不假定其来自 GeoNames。新增 test 及 test_unseen 也被评估，但本节重点汇报原数据。

输入保留 CSV 中的原问题，并追加固定格式指令：

```
{CSV sentence}
```

```
Output only JSON with numeric latitude and longitude in decimal degrees.
```

```
Answer:
```

不使用其他聊天模板、示例或坐标标签。格式方案此前通过小规模试运行确定，因此这不是完全未经查看的提示词盲测。云端 RTX5090 运行 BF16 非量化权重，batch=4，贪心生成，最多 64 个新 token。逐条原始回答保存在 direct_results_bf16_all_format/predictions.jsonl；后续审核仅重新解析和计算指标，没有再次调用模型。

只有能够解析为规定 JSON、包含有限数值 latitude/longitude 且落在合法经纬度范围内的回答才计入有效回答 MSE。有效仅表示格式和范围正确，不表示地点预测正确；(0,0) 等错误数值仍计入，距离

超过 100km 的所有有效回答也全部计入误差。无法解析或越界的回答不具备可计算坐标，不进入 MSE 分母；距离阈值命中率以全部输入条数为分母，失败回答计为未命中。

4.2 原数据表现与误差口径

数据来源	总数/有效数	有效率	有效回答 MSE	距离中位数/km	全样本 100km 内
课程 train	500/495	99.00%	161.07	15.20	69.20%
课程 valid	130/128	98.46%	513.51	35.78	63.85%
原合并	630/623	98.89%	233.48	19.75	68.10%

合并 MSE 按有效回答数加权： $(495 \times 161.072281 + 128 \times 513.512888) / 623 = 233.483835$ ，不是两个划分分数的简单平均。合并距离中位数则对 623 条距离重新求中位数，不对两个中位数加权。

4.3 经度边界与长尾样本

补充周期经度指标：把经度差变换到 $[-180^\circ, 180^\circ)$ ，仍与纬度平方误差平均。此指标用于解释地理距离，不替换课程原始 MSE，也不删除任何有效回答。

原数据部分	原始 MSE	周期经度 MSE	平均距离/km	距离 P90/km
train	161.07	109.56	201.97	332.04
valid	513.51	17.77	159.00	439.10
合并	233.48	90.70	193.14	362.83




图 6: Qwen 直接回答的原始与周期经度 MSE

这里有一个非常典型的坑。原 valid 的 Mount Tomanivi 标签经度 178.015° 、预测 -178.25° ，原始经度差为 -356.265° ，周期差为 3.735° ；该条实际距离约 397km，仍有明显误差，但它一条就贡献了原 valid 原始平方误差总和的 96.55%。因此 513.51 完全不表示典型样本定位误差达到了对应的全球尺度——这正是课程 MSE 口径的失真之处。原 train 则还存在真实的大距离错误，例如 Mount Otemanu

约 15531km，以及南极地标的错误定位；前五条贡献约 91.80% 的原始平方误差，说明长尾与实体识别值得重点分析。

4.4 对线性优化的意义及比较限制

Qwen 原 valid 距离中位数 35.78km，远低于原数据岭回归的 923.12km，但前者 MSE 仅覆盖 128 个有效回答，后者覆盖全部 130 条；两者还分别受生成失败、周期边界和选型过程影响，不能直接以 513.51 对 167.17 排出模型优劣。生成式模型还具有非线性语言模型输出头与预训练知识，不能称为与 2560 维线性头同等复杂度的替代。

这些结果表明，隐藏层线性读出误差不必然等于 Qwen 没有地理知识。优化线性头时应同时保留原始 MSE、公里距离分布和异常样本分析；可进一步尝试周期目标表示、改善表征提取位置、补充非城市样本及研究地名消歧。每种改变都应固定训练与验证协议，再在未参与选型的数据上检验。直接输出基准则需要同时报告回答覆盖率，避免通过排除失败回答获得看似更低的误差。

本报告汇总已有训练和云端推理结果，不新增模型训练。源码、逐条预测、检查点和审核记录分别位于 world_sample/neuron_network、regression_comparison 及 world_sample/direct_bf16_analysis；图像副本与来源哈希随本报告保存。三组参照共同提示：线性优化需要兼顾求解与正则化、数据域适配和地理评分口径，单纯扩大模型或训练城市样本并不能解决所有误差。

4.5 小结

解铃还须系铃人，如果 Qwen4B 在训练过程中掌握了相应的地理知识，那么把所提供数据中的原问题输入给 Qwen4B，并追加固定的输出格式指令，直觉上可能得到比线性模型更精确的预测。实验结果一定程度上支持了这一点：Qwen4B 有效回答的距离中位数明显更小，但原始 MSE 并没有稳定优势，也尚未在同一批有效样本上逐条核对是否多数预测更准确。它是完整模型的对照，不能作为单层线性模型可达到的上限。

从边界样本主导的反常损失中，我们发现对经度差作周期修正后，原验证集有效回答的 MSE 明显降低，但如果直接使用 MSE 则可能在边界情况下产生巨大误差。这也引出了下一节的内容：我们能否用球面距离来作为损失？

5 以球面距离为目标的线性坐标探测

5.1 问题与实验设计

坐标 MSE 将纬度与经度的平方误差相加，两个回归头的数据损失相互独立；它忽略经度的周期性，也没有反映同样的经度差在不同纬度对应不同地表距离。本实验保持模型为单个无激活全连接层、仅输入一个 2560 维 Qwen 层，将训练目标改为预测点与真实点的大圆中心角平方，并设置坐标 MSE 控制组。非线性仅出现在训练损失中，不出现在输入到坐标的映射中。

实验组	训练来源	调参来源	选型后评估来源
原数据组	原 train, 500 条	原 valid, 130 条	原 valid 汇报验证结果; 补充新 test 及 test_unseen
新数据组	新 train, 8382 条	新 valid, 1050 条	原 valid 跨域测试; 新 test, 1050 条; test_unseen, 1518 条

表 12: 球面损失实验的数据用途；新数据沿用 GeoNames 坐标标签，原数据沿用课程标签。

特征均值与标准差仅在相应训练集计算。设标准化特征为 z , 模型输出十进制度坐标 $p = 90(Az + a)$, 其中 A 为 2×2560 矩阵, a 为二维偏置; 乘 90 只是固定线性缩放, 不是激活或范围约束。最终导出原始特征尺度上的 weights 与 bias, 预测完全等价, 形状分别为 (2, 2560) 和 (2,)。

每组分别搜索 L11、L23、L35, Adam 学习率 0.001 或 0.003, L2 系数 0、0.001 或 0.01; 每种目标 18 个配置, 两组共 72 次初搜。训练为 float32 全批量, 最多 1200 步, 验证目标连续 150 步未改善则早停, 梯度范数裁剪为 10, 偏置不正则化。MSE 组按自身 valid 坐标 MSE 选择层、参数和检查点, 球面组按自身 valid 中心角平方选择; 全部配置冻结后再读取跨域评估标签。选定配置各以 20261005、20261006、20261007 三个种子重复训练, 不挑选最好种子。

5.2 球面损失及梯度形式

以下角度均以弧度表示。对真实点 (ϕ, λ) 和预测点 $(\hat{\phi}, \hat{\lambda})$, 设 $\Delta\lambda = \hat{\lambda} - \lambda$, 单位球向量为

$$u(\phi, \lambda) = (\cos \phi \cos \lambda, \cos \phi \sin \lambda, \sin \phi).$$

其点积与中心角满足

$$c = \sin \phi \sin \hat{\phi} + \cos \phi \cos \hat{\phi} \cos \Delta\lambda, \quad \theta = \text{atan2}(\|u \times \hat{u}\|, c).$$

这里用 atan2 代替直接计算 $\arccos(c)$, 以提高接近重合点或对跖点时的数值稳定性。为避免重合点叉积范数的梯度奇异, 训练时实际使用 $s_\varepsilon = \sqrt{\|u \times \hat{u}\|^2 + \varepsilon}$ 、 $\theta_\varepsilon = \text{atan2}(s_\varepsilon, c)$, 其中 $\varepsilon = 10^{-12}$; 最终评分不加平滑项。地球半径取 $R = 6371.0088$ 公里, 大圆距离为 $d = R\theta$ 。

两个训练目标分别为

$$L_{\text{MSE}} = \frac{1}{2N} \sum_i \left\| \frac{p_i - y_i}{90} \right\|^2 + \eta \|A\|_F^2, \quad L_{\text{sphere}} = \frac{1}{N} \sum_i \theta_{\varepsilon, i}^2 + \eta \|A\|_F^2.$$

中心角平方与距离平方仅相差 R^2 常数, 因此该目标对应距离 RMSE 意义上的优化, 并不直接最小化平均距离或距离中位数。两个目标中的数据项尺度不同, 相同 η 不意味着相同的相对正则化强度, 故各自搜索并选择参数。

对单样本球面项 $\ell = \theta_\varepsilon^2$, 利用单位向量关系 $s_\varepsilon^2 = 1 - c^2 + \varepsilon$, 链式求导得到

$$\begin{aligned} \frac{\partial \ell}{\partial c} &= -\frac{2\theta_\varepsilon}{s_\varepsilon}, & \frac{\partial c}{\partial \hat{\phi}} &= \sin \phi \cos \hat{\phi} - \cos \phi \sin \hat{\phi} \cos \Delta\lambda, \\ \frac{\partial c}{\partial \hat{\lambda}} &= -\cos \phi \cos \hat{\phi} \sin \Delta\lambda. \end{aligned}$$

于是 $\partial \ell / \partial \hat{\phi}$ 及 $\partial \ell / \partial \hat{\lambda}$ 分别由上述两项乘以 $-2\theta_\varepsilon / s_\varepsilon$ 得到。它们都依赖两个坐标, 体现了球面损失对两头输出的耦合。预测单位为度时, 还需乘以弧度换算因子 $\pi/180$ 。

设 $g_i = \partial \ell_i / \partial p_i$ 为对十进制度输出的二维梯度, 则对网络参数有

$$\frac{\partial L}{\partial A} = \frac{90}{N} \sum_i g_i z_i^\top + 2\eta A, \quad \frac{\partial L}{\partial a} = \frac{90}{N} \sum_i g_i.$$

MSE 控制组采用同一链式形式, 但单样本数据项的输出梯度为 $(p_i - y_i)/90^2$, 两坐标的误差不耦合。实现使用 PyTorch 自动微分, 并检查了重合点及对跖点附近梯度的有限性。平滑能避免数值奇异, 但不能消除球面目标的非凸性, 也不能保证对跖附近的优化方向唯一。

5.3 配置选择与结果

四组均选择 L11。原组两个目标都选择学习率 0.001、L2=0.01, 初搜最佳检查点分别为 53 和 54 步; 新 MSE 组选择学习率 0.003、L2=0.001, 最佳 1161 步, 新球面组选择学习率 0.001、L2=0.001, 最

佳 1200 步。新组部分配置达到训练上限，因此并未证明充分收敛。下表为三个种子的指标均值；MSE 按未经截断或回绕的原始坐标计算，距离按球面方向计算。

训练 / 评估来源	目标	MSE / 度 ²	平均距离 / km	距离 RMSE / km	角平方 / rad ²
原 train / 原 valid	MSE	207.46	1342.5	1734.1	0.074083
原 train / 原 valid	球面	164.17	1173.5	1432.4	0.050547
新 train / 新 valid	MSE	18.85	443.7	578.9	0.008256
新 train / 新 valid	球面	664.71	420.2	544.0	0.007291
新 train / 新 test	MSE	18.91	429.5	561.9	0.007779
新 train / 新 test	球面	663.11	403.5	510.5	0.006422
新 train / 原 valid	MSE	187.72	1247.5	1727.0	0.073482
新 train / 原 valid	球面	1790.60	1219.2	1621.1	0.064744
新 train / test_unseen	MSE	417.07	2463.5	2924.5	0.210712
新 train / test_unseen	球面	417.13	2029.3	2317.1	0.132274

原数据组验证 MSE 降低约 20.9%，平均距离降低约 12.6%，距离 RMSE 也下降。三种子原 valid MSE 分别为 207.46 ± 0.15 与 164.17 ± 3.00 ，平均距离分别为 1342.5 ± 0.4 和 1173.5 ± 5.6 公里；这些标准差描述初始化波动，不是测试不确定性。原 valid 参与检查点和参数选择，因此下降是验证结果，不能直接作为独立测试上的改善证明。本轮 MSE 控制组还低于此前岭回归 167.17 的表现，不能据此宣称球面训练全面超越既有最佳线性求解配置。

新数据组新 test 平均距离降低约 6.0%，距离 RMSE 降低约 9.1%；未见国家距离指标也有较大下降。跨域原 valid 平均距离仅降低约 2.3%，而坐标 MSE 显著增大，说明地理距离改善不等于课程坐标指标改善。此对照中的层、学习率、正则化和检查点各自选型，因此不是所有配置固定的一因素因果实验；单次数据划分和有限网格也不能代表球面目标的普遍收益。

5.4 周期等价解与原问题的启发

新球面模型的 MSE 异常不仅来自经度跨越 $\pm 180^\circ$ 。球面方向存在纬度反射等价性： (ϕ, λ) 与 $(180^\circ - \phi, \lambda + 180^\circ)$ 表示同一点，周期目标不能区分这些坐标分支。首种子新 test 出现 30 条纬度越界和 2 条经度越界，原 valid 出现 12 条纬度越界和 1 条经度越界；三个种子新 test 越界总数均为 32 条。

例如 League City 标签为 $(29.50745^\circ, -95.09493^\circ)$ ，模型输出约 $(150.73020^\circ, 92.23250^\circ)$ ，对应的球面方向等价于 $(29.26980^\circ, -87.76750^\circ)$ 。后者仍有实际定位误差，但远小于原始坐标数值差所体现的误差。我们没有将输出反射、回绕或截断成合法范围，也未剔除远距离样本，以保留完全线性的原始预测与评分；后处理为合法坐标会引入额外非线性规则，属于另一种实验。

这说明两头一起训练本身不会改变线性模型族，真正的变化来自损失对地理几何的刻画。小误差情况下中心角平方近似为 $\Delta\phi^2 + \cos^2\phi \Delta\lambda^2$ ，它会减小高纬地区经度误差的权重，并处理经度周期。然而，纯球面目标非凸且无法固定合法坐标分支，在课程按原始 MSE 评分时不宜直接替代原目标。

后续可保持同一个无激活线性层，在球面损失中加入少量坐标 MSE 或合法范围惩罚，以限制周期等价解；也应扩大优化预算并在冻结配置后做独立测试。这些是后续方向，本轮未执行。当前证据支持同时报告原始 MSE 和大圆距离，区分评分几何、坐标输出规范与实体定位能力，而不能把某个损失下降等同于全面定位改善。源码、72 次搜索、12 次重复训练及逐条预测保存在 great_circle_probe，导出权重已核验与训练模型预测一致。

5.5 小结

机器学习模型的成功与否很大程度上要看模型的假设是否合理。使用球面距离损失改变了传统最小二乘的训练目标，但输出仍是完全线性的，且能导出课程要求的权重格式；是否满足全部任务要求，还需看课程是否限定训练损失。它更符合地理和几何直觉，可以作为探索性内容研究，但本次距离改善可能伴随周期等价解及原始坐标 MSE 恶化，不能直接替代原目标。

6 创新点

这份报告牵出了以下可能作为附加实验或探究的内容：

1. 神经网络的实验效果对照：自行训练规模较小的神经网络进行 world/truth 任务，作为线性模型效果的对照
2. 其他回归/分类模型的实验效果对照：自行学习并使用 sklearn 提供的其他回归和分类模型作为实验效果的对照，并分析不同建模方法的利弊
3. truth 数据集的构造方法分析：基于公开数据集的数据增强发现，以及其对模型/该任务的意义
4. Qwen 直接输出经纬度的采样：自行部署 Qwen4B 并比较其直接输出的经纬度和标签，作为线性模型的改进空间参照
5. 以球面/地理距离为损失的模型设计：以经度边界的高经度差和低地理距离现象为基础，设计地理上/几何上更合理的损失函数并作为对比。

7 数据与图像来源

- GeoNames 数据下载及字段说明 (<https://download.geonames.org/export/dump/>)，数据许可为 CC BY 4.0。
- Qwen 模型固定版本(<https://huggingface.co/Qwen/Qwen3-4B-Base/tree/906bfd4b4dc7f14ee4320094d8b41684abff8>)
- 神经网络对照：world_sample/neuron_network；sklearn 回归对照：regression_comparison；Qwen 直接输出：world_sample/direct_bf16_analysis；truth 分类基准：regression_comparison/truth_results。
- 本报告不新增模型训练，全部图像与汇总指标均从上述目录复制，来源路径与 SHA256 见 figure_manifest.json 与 verification.json。

8 注意事项

- 不要把不同选型协议的数值混作同一套证据：本报告中”按原 valid 选型”与”按新 valid 选型”的分数不可直接比较，报告 1 的交叉验证选型也不属于同一协议。
- 合并分数要说明加权方式：原 630 条的 MSE 按有效回答数或样本数加权，不是两个划分分数的简单平均。
- 同域最优不保证跨域最优：按新 valid 选出的最佳方法，在原数据上可能反而更差；跨域结论需要未参与选型的保留样本。
- 线性头并非被”非线性”击败：本报告多数非线性方法的优势有限，岭回归仍是稳健参照。在报告里不要把”某非线性方法分数更高”直接写成”线性不如非线性”。
- 评分口径会扭曲排序：原始经纬度 MSE 受经度跨界影响极大，单条样本可支配整体误差；应同时报告公里距离分布与异常样本。
- 报告 1 的岭参数量纲坑在本报告中同样存在：sklearn 岭回归的 alpha 是”平方误差总和”，若与”平均平方误差 + lambda”的目标比较，须按 $\alpha = n \times \lambda$ 换算。